Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

Лабораторная работа №4

Метод k-ближайших соседей

Датасет Wine

Выполнили: Ясаков Артём
Сарваров Тимур

Группа: P3313

Проверил: Жданов Андрей Дмитриевич

Санкт-Петербург, 2026 г.

Contents

1 Цель работы **2**

2 Описание датасета **2**

3 Предварительная обработка данных **2**

3.1 Обработка пропусков 2

3.2 Кодирование категориальных признаков 2

3.3 Разделение и масштабирование 2

4 Статистика и визуализация **3**

4.1 Описательная статистика 3

4.2 Гистограммы признаков 4

4.3 3D-визуализация 4

5 Реализация метода k-NN **5**

5.1 Алгоритм 5

5.2 Векторизация расстояний 6

6 Две модели с разными наборами признаков **6**

6.1 Модель 1 — случайные признаки 6

6.2 Модель 2 — фиксированный набор 6

7 Результаты экспериментов **6**

7.1 Точность при разных k 6

7.2 Матрицы ошибок 7

8 Анализ результатов **8**

9 Выводы **8**

Использование искусственного интеллекта **9**

1 Цель работы

Изучить метод k-ближайших соседей (k-NN) и реализовать его «с нуля» на языке Python, используя только библиотеки `NumPy` и `Pandas`. Провести предварительную обработку данных, визуализировать статистику, построить две модели k-NN с разными наборами признаков, оценить их качество при различных значениях k и построить матрицы ошибок.

2 Описание датасета

Используется встроенный датасет `load_wine` из `sklearn.datasets`. Он содержит результаты химического анализа вин, выращенных в одном регионе Италии, но полученных из трёх разных сортов винограда.

- Количество образцов: **178**
- Количество признаков: **13** (все числовые)
- Количество классов: **3**
- Признаки: `alcohol`, `malic_acid`, `ash`, `alcalinity_of_ash`, `magnesium`, `total_phenols`, `flavanoids`, `nonflavanoid_phenols`, `proanthocyanins`, `color_intensity`, `hue`, `od280/od315_d` `proline`.

Датасет сбалансированный, пропусков нет, категориальных признаков нет.

3 Предварительная обработка данных

3.1 Обработка пропусков

Проверка наличия пропущенных значений выполняется командой `df.isnull().sum()`. В датасете Wine пропусков нет ни в одном из столбцов, поэтому заполнение медианой фактически не требуется. Тем не менее в коде предусмотрена процедура `fillna` на случай появления пропусков.

3.2 Кодирование категориальных признаков

Категориальные признаки отсутствуют, поэтому one-hot кодирование (`pd.get_dummies`) не применяется. Проверка выполняется автоматически: `Категориальные признаки: нет`.

3.3 Разделение и масштабирование

Датасет делится на обучающую и тестовую выборки в соотношении 70 / 30 со стратификацией по классу. Масштабирование выполняется по статистикам *обучающей* выборки (чтобы избежать утечки данных):

$$x' = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}},$$

где μ_{train} и σ_{train} — среднее и стандартное отклонение по каждому признаку на обучающей выборке. Нулевые σ заменяются на 1. Итоговые размеры выборок: train = $(124, 13)$, test = $(54, 13)$.

4 Статистика и визуализация

4.1 Описательная статистика

Для масштабированных признаков рассчитаны: количество, среднее, стандартное отклонение, минимум, квартили 25 %, 50 %, 75 %, максимум. Фрагмент результата приведён в таблице 1.

Table 1: Описательная статистика масштабированных признаков (фрагмент)

Признак	count	mean	std	max
alcohol	124	0.0	1.0	2.319
malic_acid	124	0.0	1.0	3.328
ash	124	0.0	1.0	3.195
alcalinity_of_ash	124	0.0	1.0	3.063
magnesium	124	−0.0	1.0	4.084
total_phenols	124	0.0	1.0	2.541
flavanoids	124	0.0	1.0	1.822
nonflavanoid_phenols	124	−0.0	1.0	2.302
proanthocyanins	124	0.0	1.0	3.425
color_intensity	124	−0.0	1.0	3.376
hue	124	0.0	1.0	3.302
od280/od315_of_diluted_wines	124	0.0	1.0	1.932
proline	124	−0.0	1.0	2.499

Как и ожидалось, после стандартизации каждый признак имеет mean ≈ 0 и std $= 1$.

4.2 Гистограммы признаков

Распределения масштабированных признаков представлены на рисунке 1. Часть признаков (`alcohol`, `ash`, `flavanoids`) близка к нормальному распределению, другие (`malic_acid`, `color_intensity`, `proline`) имеют заметную правостороннюю асимметрию.

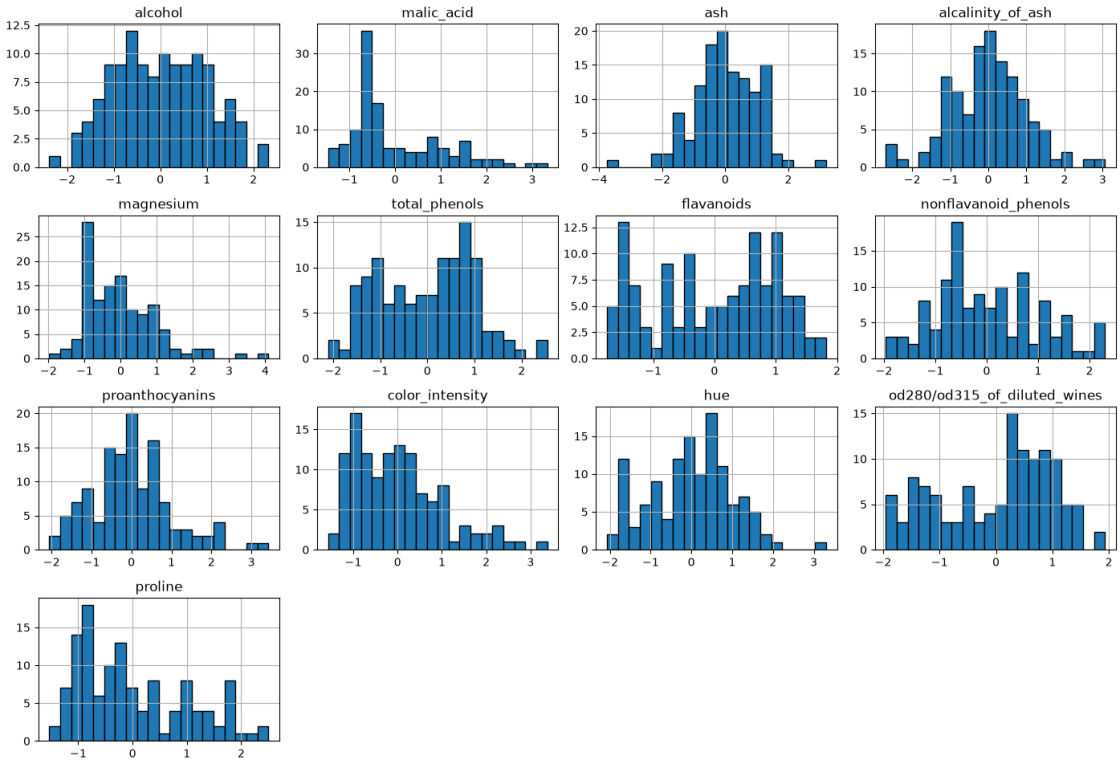


Figure 1: Распределение масштабированных признаков

4.3 3D-визуализация

Для визуализации выбраны признаки `alcohol`, `flavanoids` и `color_intensity`. Из рисунка 2 видно, что классы достаточно хорошо разделимы в этом подпространстве: класс 0 (красный) чётко отделён от классов 1 и 2 (зелёный, синий), а классы 1 и 2 пересекаются между собой сильнее.

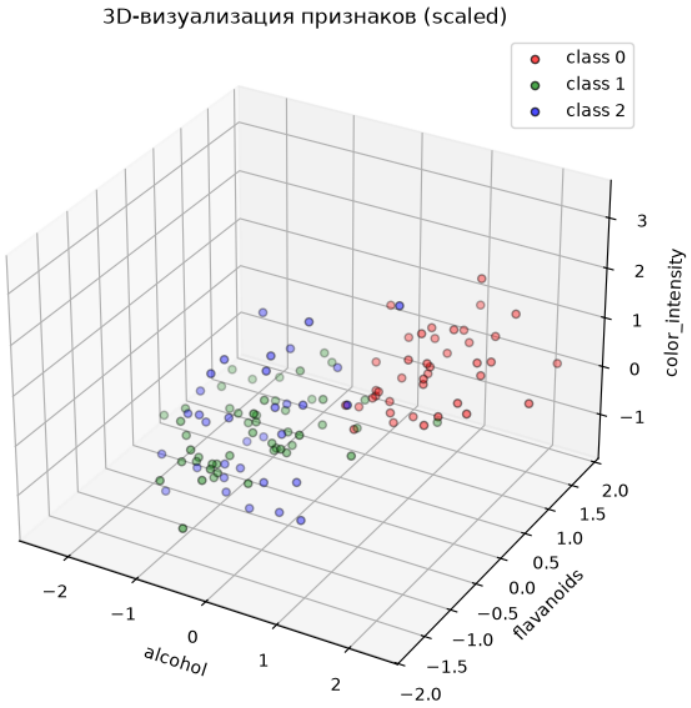


Figure 2: 3D-визуализация трёх признаков (scaled)

5 Реализация метода k-NN

Метод k-ближайших соседей реализован «с нуля», без использования готовых реализаций `sklearn` (кроме загрузки датасета и `train_test_split`).

5.1 Алгоритм

1. Обучающая выборка запоминается целиком (ленивое обучение).
2. Для каждой тестовой точки вычисляется евклидово расстояние до всех обучающих:

$$d(x, x_i) = \sqrt{\sum_{j=1}^{d} (x_j - x_{ij})^2}.$$

3. Находятся k ближайших соседей.
4. Класс определяется мажоритарным голосованием:

$$\hat{y}(x) = \arg\max_{c} \sum_{i \in N_k(x)} \mathbb{1}[y_i = c].$$

5.2 Векторизация расстояний

Для ускорения вычислений используется тождество:

$$\|a - b\|^2 = \|a\|^2 + \|b\|^2 - 2\, a \cdot b,$$

что позволяет вычислить всю матрицу расстояний ($n_{\text{test}} \times n_{\text{train}}$) за одно матричное умножение вместо двойного цикла.

Матрица ошибок и метрика accuracy также реализованы вручную — без `sklearn.metrics`.

6 Две модели с разными наборами признаков

6.1 Модель 1 — случайные признаки

Случайно (с фиксированным `seed = 42`) отбирается половина признаков. Отобранный набор: `od280/od315_of_diluted_wines`, `color_intensity`, `alcohol`, `proanthocyanins`, `total_phenols`, `ash` (6 из 13).

6.2 Модель 2 — фиксированный набор

Заранее выбраны пять наиболее информативных, по нашему мнению, признаков для классификации вин: `alcohol`, `flavanoids`, `color_intensity`, `proline`, `total_phenols`. Фенольные соединения и интенсивность цвета хорошо различают сорта винограда, поэтому этот набор ожидаемо даёт высокое качество.

7 Результаты экспериментов

7.1 Точность при разных k

Значения k: $1, 3, 5, 7, 10, 15$. Результаты приведены в таблице 2 и на рисунке 3.

Table 2: Точность моделей при разных k

k	Model 1 (random features)	Model 2 (fixed features)
1	0.8889	0.9630
3	0.8889	0.9630
5	0.9074	0.9630
7	**0.9259**	0.9630
10	0.8889	**0.9815**
15	0.8889	0.9444

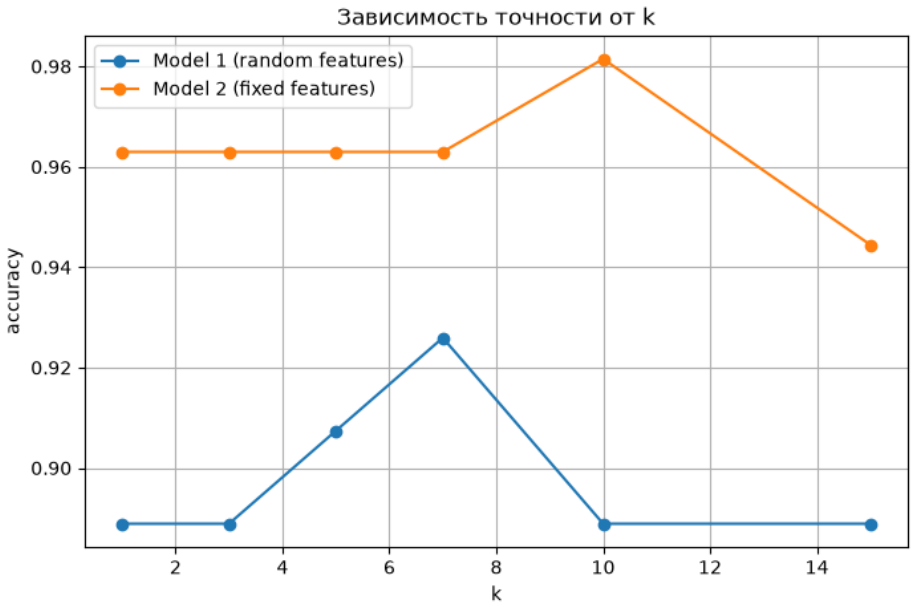


Figure 3: Зависимость точности от k

7.2 Матрицы ошибок

На рисунке 4 приведены матрицы ошибок для обеих моделей при всех рассмотренных k. Верхний ряд — Модель 1 (случайные признаки), нижний — Модель 2 (фиксированные признаки).

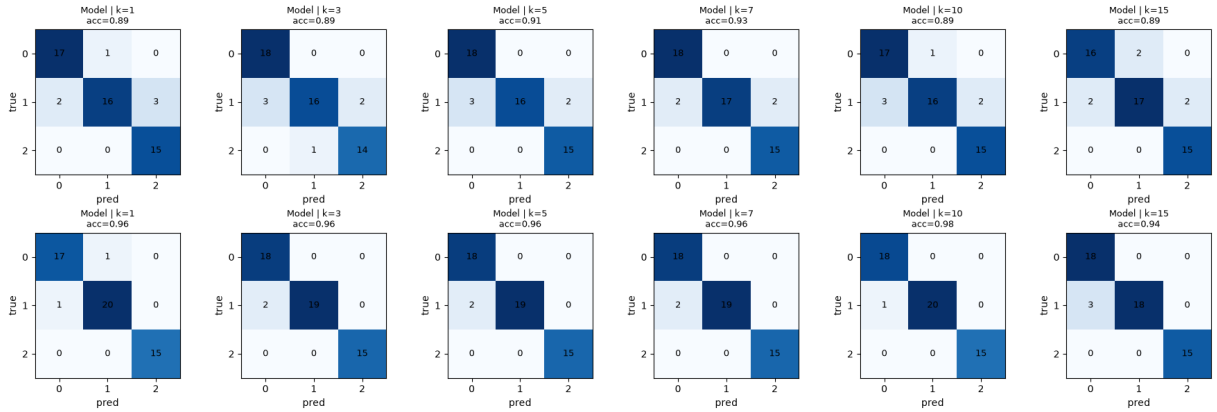


Figure 4: Матрицы ошибок для обеих моделей при разных k

8 Анализ результатов

- **Модель 2** (фиксированные признаки) стабильно даёт точность ≈ 0.96, достигая максимума 0.9815 при $k = 10$.
- **Модель 1** (случайные признаки) показывает более низкую и нестабильную точность: 0.889 на большинстве k, с локальным максимумом 0.926 при $k = 7$. Это объясняется тем, что случайный набор не содержит `flavanoids` и `proline` — два наиболее разделяющих признака.
- При $k = 1$ модель чувствительна к шуму и выбросам, но в силу структурированности датасета Wine сильного падения точности не наблюдается.
- При $k = 15$ точность обеих моделей немного снижается из-за «размытия» границ решающей области.
- По матрицам ошибок видно, что класс 0 распознаётся почти безошибочно, а основные ошибки возникают между классами 1 и 2. В Модели 1 при $k = 1$ наблюдается 3 ошибочных отнесения класса 1 в класс 2; в Модели 2 такие ошибки практически отсутствуют.

9 Выводы

В ходе лабораторной работы:

1. Проведена предварительная обработка датасета Wine: проверка пропусков (их нет), кодирование категориальных признаков (их нет), масштабирование по статистикам обучающей выборки.
2. Построена описательная статистика (mean ≈ 0, std $= 1$ после масштабирования) и визуализация: гистограммы и 3D-скаттер по признакам `alcohol`, `flavanoids`, `color_intensity`.
3. Реализован метод k-NN «с нуля» на `NumPy` и `Pandas` с векторным вычислением евклидовых расстояний.
4. Построены две модели с разными наборами признаков и проведено их сравнение при $k = 1, 3, 5, 7, 10, 15$.
5. Показано, что выбор информативных признаков критически влияет на качество классификации: Модель 2 с фиксированным набором (accuracy до 0.9815) устойчиво превосходит Модель 1 со случайным набором (accuracy ≈ 0.89–0.93).

Использование искусственного интеллекта

В ходе выполнения лабораторной работы применялись инструменты искусственного интеллекта в качестве вспомогательного средства. Конкретные сценарии использования:

1. **Разбор задания.** Уточнение требований к реализации метода k-NN «с нуля» и корректной интерпретации пунктов про две модели с разными наборами признаков.
2. **Проверка логики реализации.** Обсуждение векторного вычисления евклидовых расстояний через тождество $\|a - b\|^2 = \|a\|^2 + \|b\|^2 - 2a \cdot b$ и корректности ручной реализации матрицы ошибок и метрики accuracy.
3. **Пояснение этапов обработки данных.** Разъяснение смысла масштабирования по статистикам обучающей выборки и необходимости стратификации при разбиении датасета.
4. **Оформление отчёта.** Помощь в структурировании разделов, оформлении таблиц и вставке графиков средствами LaTeX.
5. **Анализ результатов.** Обсуждение возможных причин различия в точности между Моделью 1 и Моделью 2.