Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

Лабораторная работа №6

Логистическая регрессия

Датасет Titanic

Выполнили: Ясаков Артём
Сарваров Тимур

Группа: P3313

Проверил: Жданов Андрей Дмитриевич

Санкт-Петербург, 2026 г.

Contents

1 Цель работы **2**

2 Описание датасета **2**

2.1 Используемые признаки 2

3 Предварительная обработка данных **2**

3.1 Пропущенные значения 2

3.2 Кодирование категориальных признаков 3

3.3 Нормализация 3

3.4 Разделение данных 3

4 Статистика и визуализация **3**

4.1 Описательная статистика 3

4.2 Гистограммы признаков 4

5 Реализация логистической регрессии **4**

5.1 Сигмоидная функция (гипотеза) 4

5.2 Функция потерь (Log Loss / Binary Cross-Entropy) 5

5.3 Градиентный спуск 5

5.4 Метод Ньютона (Newton-Raphson) 5

5.5 Метрики качества 5

6 Исследование гиперпараметров **6**

6.1 Влияние learning rate 6

6.2 Влияние количества итераций 6

6.3 Метод Ньютона 6

6.4 Визуализация 7

7 Финальная модель **8**

8 Анализ результатов **9**

9 Выводы **9**

Использование искусственного интеллекта **11**

1 Цель работы

Изучить метод логистической регрессии и реализовать его «с нуля» на языке Python, используя только библиотеки `NumPy` и `Pandas`. Провести предварительную обработку данных датасета Titanic, визуализировать статистику, исследовать влияние гиперпараметров (learning rate, количество итераций, метод оптимизации) на качество модели. Оценить модель с помощью метрик Accuracy, Precision, Recall и F1-Score.

2 Описание датасета

Используется датасет `titanic` из библиотеки `seaborn`. Он содержит информацию о пассажирах трагически известного лайнера «Титаник», затонувшего в 1912 году. Целевая переменная — выжил ли пассажир (`survived`: 0 — погиб, 1 — выжил).

- Количество образцов: **891**
- Количество исходных признаков: **15**
- Тип задачи: бинарная классификация
- Классы: погиб (0) — 549 чел. (61.6%), выжил (1) — 342 чел. (38.4%)

2.1 Используемые признаки

Из исходных столбцов были отобраны следующие признаки для моделирования:

- `pclass` — класс билета (1, 2, 3)
- `sex` — пол (`male` / `female`)
- `age` — возраст (годы)
- `sibsp` — количество братьев/сестёр/супругов на борту
- `parch` — количество родителей/детей на борту
- `fare` — стоимость билета
- `embarked` — порт посадки (C = Cherbourg, Q = Queenstown, S = Southampton)

Столбцы `deck` (слишком много пропусков — 688), `alive` (дублирует целевую), `class`, `who`, `adult_male`, `alone` не использовались.

3 Предварительная обработка данных

3.1 Пропущенные значения

В исходном датасете присутствуют пропуски: `age` — 177 значений (19.9%), `embarked` — 2 значения (0.2%), `deck` — 688 значений (77.2%). Признак `deck` исключён из анализа. Пропуски в `age` и `fare` заполнены медианным значением соответствующего столбца: $\tilde{x}_{\text{age}} = 28$, $\tilde{x}_{\text{fare}} = 14.45$. Пропуски в `embarked` незначительны (2 шт.) и также заполнены модой.

3.2 Кодирование категориальных признаков

Признак `sex` преобразован в бинарный: female = 1, male = 0. Признаки `embarked` и `pclass` преобразованы с помощью one-hot кодирования (`pd.get_dummies`) с параметром `drop_first=True` для избежания мультиколлинеарности. Итоговый набор — 9 числовых признаков: `sex`, `age`, `sibsp`, `parch`, `fare`, `embarked_Q`, `embarked_S`, `pclass_2`, `pclass_3`.

3.3 Нормализация

Все признаки масштабированы с помощью `StandardScaler`:

$$x' = \frac{x - \mu}{\sigma},$$

где μ — среднее, σ — стандартное отклонение признака. Масштабирование необходимо для стабильной сходимости градиентного спуска и корректной работы регуляризации.

3.4 Разделение данных

Датасет разделён на обучающую и тестовую выборки в соотношении **80 / 20** со стратификацией по целевой переменной (`stratify=y`). Итоговые размеры:

$$\text{train} = 712 \text{ образцов}, \quad \text{test} = 179 \text{ образцов}.$$

Доля выживших: train — 38.3%, test — 38.5% (одинакова благодаря стратификации).

4 Статистика и визуализация

4.1 Описательная статистика

В таблице 1 приведена описательная статистика признаков до масштабирования: количество, среднее, стандартное отклонение, минимум, квартили, максимум.

Table 1: Описательная статистика признаков (до масштабирования)

Признак	count	mean	std	min	25%	50%	max
sex	891	0.352	0.478	0	0	0	1
age	891	29.36	13.02	0.42	22.0	28.0	80.0
sibsp	891	0.523	1.103	0	0	0	8
parch	891	0.382	0.806	0	0	0	6
fare	891	32.20	49.69	0	7.91	14.45	512.33
embarked_Q	891	0.086	0.281	0	0	0	1
embarked_S	891	0.723	0.448	0	0	1	1
pclass_2	891	0.207	0.405	0	0	0	1
pclass_3	891	0.551	0.498	0	0	1	1

Из таблицы видно, что 72.3% пассажиров сели в порту Southampton, 55.1% путешествовали третьим классом, средний возраст — около 29 лет. Признак `fare` имеет сильную правостороннюю асимметрию (медиана 14.45, максимум — 512.33).

4.2 Гистограммы признаков

Распределения признаков представлены на рисунке 1. Вертикальными линиями отмечены среднее (красная) и медиана (зелёная).

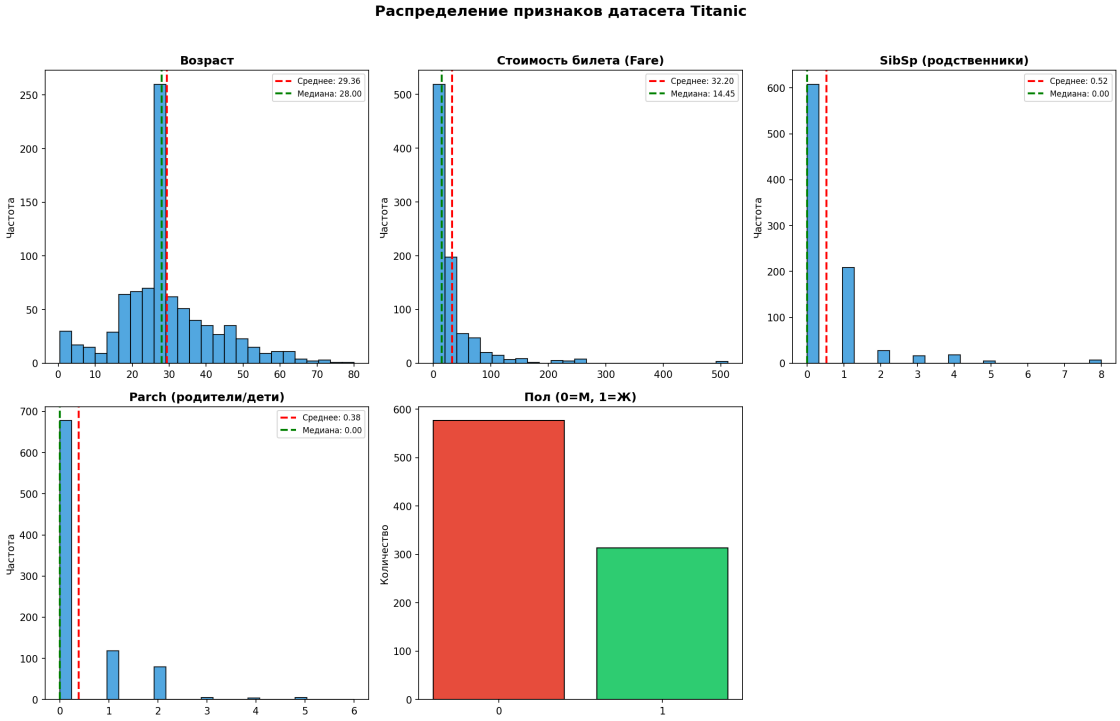


Figure 1: Распределение признаков датасета Titanic

5 Реализация логистической регрессии

Модель логистической регрессии реализована «с нуля» без использования готовых реализаций `sklearn` (кроме `train_test_split` и `StandardScaler`). Реализация включает два класса, два метода оптимизации и самостоятельный расчёт метрик.

5.1 Сигмоидная функция (гипотеза)

Сигмоидная функция преобразует линейную комбинацию признаков в вероятность принадлежност к классу 1:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = w^T x + b.$$

Для численной устойчивости аргумент z обрезается до диапазона $[-500, 500]$ перед вычислением экспоненты.

5.2 Функция потерь (Log Loss / Binary Cross-Entropy)

$$\mathcal{L}(w, b) = -\frac{1}{n}\sum_{i=1}^{n}\big[y_i \ln \hat{y}_i + (1 - y_i)\ln(1 - \hat{y}_i)\big],$$

где $\hat{y}_i = \sigma(w^T x_i + b)$. Для предотвращения $\ln(0)$ вероятности обрезаются до $[10^{-15}, 1 - 10^{-15}]$.

5.3 Градиентный спуск

Градиенты функции потерь по параметрам:

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{1}{n} X^T(\hat{y} - y), \qquad \frac{\partial \mathcal{L}}{\partial b} = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i).$$

Правило обновления:

$$w := w - \eta \frac{\partial \mathcal{L}}{\partial w}, \quad b := b - \eta \frac{\partial \mathcal{L}}{\partial b},$$

где η — коэффициент обучения (learning rate). Класс — `LogisticRegressionGD`.

5.4 Метод Ньютона (Newton-Raphson)

Метод Ньютона использует вторые производные (матрицу Гессе) для более быстрой сходимости:

$$H = \frac{1}{n} X_{\text{aug}}^T \, S \, X_{\text{aug}},$$

где $S = \operatorname{diag}\big(\hat{y}_i(1 - \hat{y}_i)\big)$, $X_{\text{aug}} = [X \mid \mathbf{1}]$.

Градиент и Гессиан объединяются для параметров w и b:

$$\theta := \theta - H^{-1}\nabla\mathcal{L}(\theta).$$

Для устойчивости к матрице Гессе добавляется регуляризация: $H_{\text{reg}} = H + 10^{-5} I$. Класс — `LogisticRegressionNewton`.

5.5 Метрики качества

Все метрики реализованы вручную (функция `compute_metrics`):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN},$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

6 Исследование гиперпараметров

Проведено исследование влияния трёх гиперпараметров на качество модели: коэффициента обучения η, количества итераций N и метода оптимизации (градиентный спуск vs метод Ньютона).

6.1 Влияние learning rate

Исследованы значения $\eta \in \{0.001, 0.01, 0.05, 0.1, 0.5, 1.0\}$ при фиксированном $N = 5000$. Результаты приведены в таблице 2.

Table 2: Влияние learning rate (GD, $N = 5000$)

η	Accuracy	Precision	Recall	F1-Score
0.001	0.7765	0.7302	0.6667	0.6970
0.01	0.7989	0.7797	0.6667	0.7188
0.05	0.8045	0.7931	0.6667	0.7244
0.1	**0.8045**	**0.7931**	0.6667	**0.7244**
0.5	0.8045	0.7931	0.6667	0.7244
1.0	0.8045	0.7931	0.6667	0.7244

При $\eta = 0.001$ модель сходится медленно. При $\eta \geq 0.05$ результаты стабилизируются. Расходимость при больших η на данном датасете не наблюдается благодаря нормализации.

6.2 Влияние количества итераций

Исследованы $N \in \{100, 500, 1000, 5000, 10000\}$ при $\eta = 0.1$. Результаты в таблице 3.

Table 3: Влияние количества итераций (GD, $\eta = 0.1$)

N	Accuracy	Precision	Recall	F1-Score
100	0.7989	0.7797	0.6667	0.7188
500	0.7989	0.7797	0.6667	0.7188
1000	0.8045	0.7931	0.6667	0.7244
5000	0.8045	0.7931	0.6667	0.7244
10000	**0.8045**	**0.7931**	0.6667	**0.7244**

Модель выходит на плато уже при $N = 1000$, дальнейшее увеличение итераций не даёт существенного прироста качества.

6.3 Метод Ньютона

Исследованы $N \in \{3, 5, 10, 15, 20, 30, 50\}$. Результаты приведены в таблице 4.

Table 4: Результаты метода Ньютона

N	Accuracy	Precision	Recall	F1-Score
3	0.8045	0.7931	0.6667	0.7244
5	0.8045	0.7931	0.6667	0.7244
10	0.8045	0.7931	0.6667	0.7244
15	0.8045	0.7931	0.6667	0.7244
20	0.8045	0.7931	0.6667	0.7244
30	0.8045	0.7931	0.6667	0.7244
50	0.8045	0.7931	0.6667	0.7244

Метод Ньютона сходится к оптимальным параметрам уже за **3 итерации**, тогда как градиентному спуску требуется ~ 1000 итераций. При этом финальные метрики идентичны — точность не зависит от метода оптимизации (оба сходятся к одному и тому же оптимуму).

6.4 Визуализация

На рисунке 2 представлены графики зависимости метрик от гиперпараметров, а на рисунке 3 — тепловая карта Accuracy для всех комбинаций η и N (градиентный спуск).

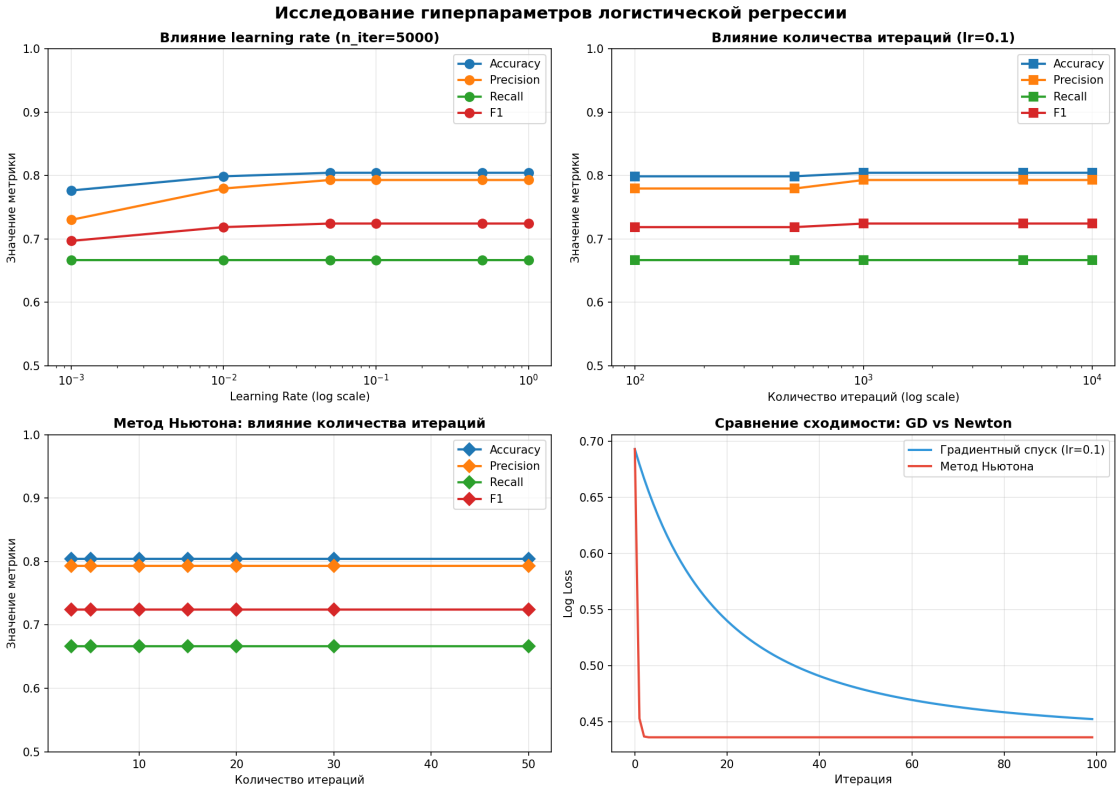


Figure 2: Зависимость метрик от гиперпараметров

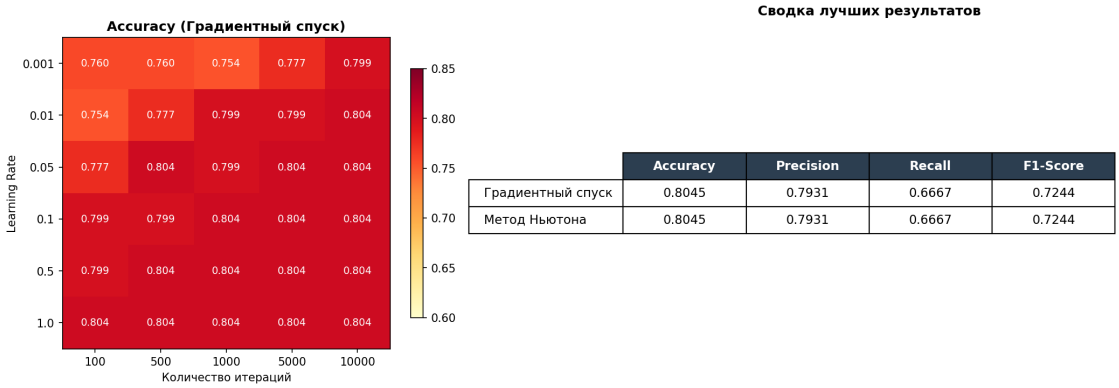


Figure 3: Тепловая карта Accuracy и сводная таблица

7 Финальная модель

С оптимальными гиперпараметрами ($\eta = 0.1$, $N = 10000$, градиентный спуск) получены следующие результаты на тестовой выборке:

Table 5: Финальные метрики модели

Метрика	Значение
Accuracy	0.8045
Precision	0.7931
Recall	0.6667
F1-Score	0.7244

Матрица ошибок:

$$\begin{bmatrix} \text{TN} = 98 & \text{FP} = 12 \\ \text{FN} = 23 & \text{TP} = 46 \end{bmatrix}$$

Модель правильно классифицирует 98 из 110 погибших (Recall для класса «погиб» ≈ 0.89), но лишь 46 из 69 выживших (Recall для класса «выжил» ≈ 0.67). Это означает, что модель чаще ошибается в сторону предсказания «погиб», что консервативно и соответствует априорному распределению классов (61.6% — погибшие).

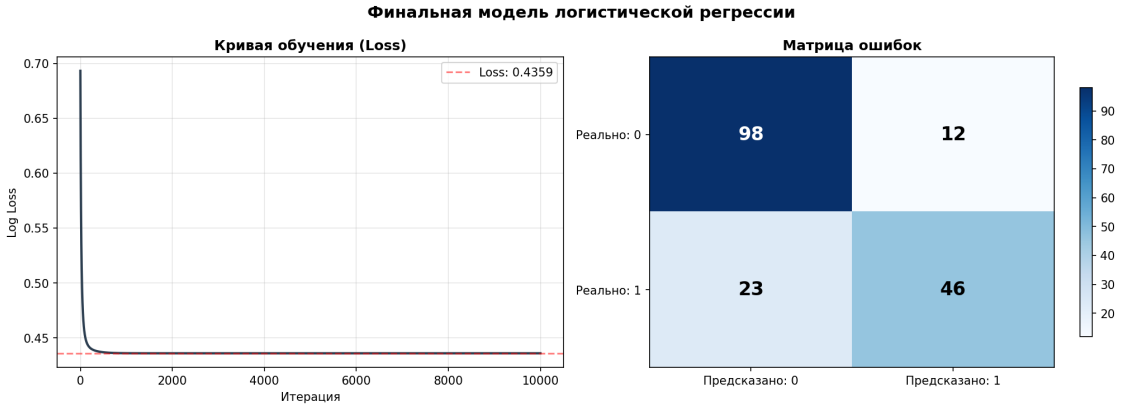


Figure 4: Кривая обучения и матрица ошибок

8 Анализ результатов

- **Learning rate:** при $\eta = 0.001$ модель сходится слишком медленно (Accuracy $\approx$ 0.78). Оптимальный диапазон: $\eta \in [0.01, 0.1]$. При $\eta \geq 0.5$ расходимости не происходит благодаря нормализации, но на более сложных датасетах возможна нестабильность.

- **Количество итераций:** при $N = 100$ модель уже даёт Accuracy ≈ 0.80. После $N = 1000$ наступает плато, дальнейшее обучение не улучшает метрики. Рекомендация: $N = 5000$–10000 для надёжности.

- **Метод оптимизации:** метод Ньютона сходится за 3–5 итераций против ~ 1000 для градиентного спуска, но требует вычисления и обращения матрицы Гессе размера $(d+1) \times (d+1)$ ($O(d^3)$). Для данного датасета ($d = 9$) разница в скорости несущественна.

- **Precision vs Recall:** Precision (0.79) выше, чем Recall (0.67). Модель осторожна с предсказанием класса «выжил» — предпочитает пропустить выжившего, чем ошибочно предсказать выживание погибшему.

- **Общее качество:** Accuracy $= 0.8045$ — хороший результат для базовой логистической регрессии без feature engineering. Результат сопоставим с известными baseline для Titanic. Качество можно улучшить добавлением взаимодействий признаков (например, Age $\times$ Pclass), полиномиальных признаков и регуляризации L2.

9 Выводы

В ходе лабораторной работы:

1. Загружен датасет Titanic (891 пассажир, 15 исходных признаков), проведена предварительная обработка: отбор признаков (7 содержательных), заполнение пропусков медианой,

one-hot кодирование категориальных переменных, нормализация StandardScaler. Итоговый набор — 9 числовых признаков.

2. Рассчитана и визуализирована описательная статистика: средние, стандартные отклонения, квартили, гистограммы распределений с наложением среднего и медианы.

3. Данные разделены на обучающую (80%) и тестовую (20%) выборки со стратификацией по целевой переменной.

4. Реализована логистическая регрессия «с нуля» на `NumPy` и `Pandas`: сигмоида, log loss, градиентный спуск, метод Ньютона. Метрики Accuracy, Precision, Recall, F1-Score реализованы вручную.

5. Проведено исследование гиперпараметров: learning rate $\{0.001, \ldots, 1.0\}$, количество итераций $\{100, \ldots, 10000\}$, метод оптимизации (GD и Newton).

6. Наилучшие результаты: Accuracy = **0.8045**, F1-Score = **0.7244** при $\eta = 0.1$, $N = 10000$. Метод Ньютона достигает тех же метрик за 3 итерации.

Использование искусственного интеллекта

В ходе выполнения лабораторной работы применялись инструменты искусственного интеллекта в качестве вспомогательного средства. Конкретные сценарии использования:

1. **Разбор задания.** Уточнение требований к реализации логистической регрессии «с нуля», интерпретация пунктов про исследование гиперпараметров и два метода оптимизации (градиентный спуск и метод Ньютона).

2. **Реализация метода Ньютона.** Помощь в корректной реализации вычисления матрицы Гессе, её регуляризации и решения системы линейных уравнений для обновления параметров.

3. **Численная устойчивость.** Рекомендации по обрезанию аргумента сигмоиды до $[-500, 500]$ и вероятностей до $[10^{-15}, 1 - 10^{-15}]$ для предотвращения переполнения.

4. **Пояснение этапов обработки данных.** Объяснение необходимости one-hot кодирования с `drop_first`, нормализации для сходимости градиентного спуска и роли стратификации при разбиении.

5. **Оформление отчёта.** Помощь в структурировании разделов, оформлении таблиц с результатами экспериментов и вставке графиков средствами LaTeX.

6. **Анализ результатов.** Интерпретация метрик Precision и Recall в контексте несбалансированности классов, обсуждение преимуществ и недостатков метода Ньютона по сравнению с градиентным спуском.